

Generative Adversarial Networks (GANs)

Ion Goodfellow, 2014

- Dos redes compitiendo entre sí (Adversarial)


- 1° Generador (datos sintéticos)
- 2° Discriminador (clasificar reales vs sintéticos)

Generadores:

- Muestra números aleatorios: vector z
- Con layers ocultos mapea z en datos sintéticos (genera fakes)

Discriminador:

- Se entrena para no dejarse engañar



Optimización

- Fakes, maximizar $\log p(\hat{y}=0|x)$
- Real, maximizar $\log p(\hat{y}=1|x)$

$$\mathcal{L} = \mathbb{E}[\log D(x)] + \mathbb{E}[\log (1 - D(G(z)))]$$


$$= \text{BCE}(D(x), 1) + \text{BCE}(D(G(z)), 0) \quad ; \quad \text{BCE: binary cross entropy}$$

$$= D_{JS} : \text{Divergence Jensen-Shannon}$$

Variantes

- Conditional GAN (cGAN)

• Incluyen información sobre contexto (ej. clases)



- Wasserstein GAN (WGAN)

• Optimización unificada

→ Sub modelos ya no compiten en términos de optimización, sino que colaboran

→ la pérdida comienza a parecerse a una curva monótona

• Implementación:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N y_i \hat{y}_i \quad ; \quad N: \text{tamaño de la muestra}$$

Paréntesis: Divergence Kullback-Leibler

- Divergencia entre dos pdf's P y Q
- Notión del costo a pagar por suponer que nuestros datos son generados por P , cuando realmente son generados por Q

$$D_{KL}(P||Q) = \sum_{x \in X} P(x) \log \left(\frac{P(x)}{Q(x)} \right)$$



Divergence Jensen-Shannon

$$D_{JS}(P||Q) = \frac{1}{2} D_{KL}(P||M) + \frac{1}{2} D_{KL}(Q||M)$$

donde $M = \frac{1}{2}(P+Q)$

EN MEMORIA

