

Aprendizaje Supervisado: Regresión Logística.

Guillermo Santamaría-Bonfil

Agenda

- **Regresión Logística.**
 - Odds/Log odds
 - Porque no regresión lineal
 - Derivación de la función

Antecedentes: Odds Ratio

Razón de Momios

Razón de oportunidades

Razón de probabilidades


} Odds ratio

Una de las principales funciones en la estadística para cuantificar:

Cuan fuerte es

la presencia o ausencia de la propiedad A asociada con

la presencia o ausencia de la propiedad B en una población.



E.g.

La razón de probabilidad (odds ratio) describe cuantitativamente la asociación entre la presencia/ausencia de A (gripa) y la presencia/ausencia de B (exposición al virus) para los individuos de la población.

Cálculo de Odds Ratio (OR)


1. Para un individuo que tiene B (expuesto a la gripa) calcular los odds de que también tenga A (gripa).
2. Para un individuo que no tiene B (no estuvo expuesto) calcular los odds de que también tenga A (gripa).
3. Dividir los odds de 1 entre los odds de 2, para obtener OR.

Si $OR = 1 \rightarrow$ La exposición a B no afecta A

Si $OR < 1 \rightarrow$ A se considera asociada con B (baja la posibilidad)

Si $OR > 1 \rightarrow$ A se considera asociada con B (sube la posibilidad)

Nota: ESTO **NO IMPLICA CAUSALIDAD: B CAUSA A**



	ENFERMO (GRIPA)	SANO (NO GRIPA)
EXPUESTO	$G_E = 4$	$S_E = 1$
NO- EXPUESTO	$G_{NE} = 1$	$S_{NE} = 2$

1. Tener gripa dado que estuvo expuesto: $\frac{G_E}{S_E} = 4$

2. Tener gripa dado que no estuvo expuesto: $\frac{G_{NE}}{S_{NE}} = \frac{1}{2}$

$$3. OR = \frac{\frac{G_E}{S_E}}{\frac{G_{NE}}{S_{NE}}} = \frac{G_E S_{NE}}{G_{NE} S_E} = \frac{\frac{G_E}{S_E}}{\frac{G_{NE}}{S_{NE}}} = \frac{4}{\frac{1}{2}} = 8$$


¿Qué implica este resultado?

Antecedentes:

Log Odds

- El logaritmo de la razón de momios...
- Alternativa para expresar probabilidades simplificando el proceso de actualización con nueva evidencia
- Logit
- Función inversa de la función sigmoideal logística.

	ENFERMO (GRIPA)	SANO (NO GRIPA)
EXPUESTO	$G_E=4$	$S_E=1$
NO- EXPUESTO	$G_{NE}=1$	$S_{NE}=2$



$$\text{logit}(P(A)) = \log \left(\frac{P(A)}{P(\neg A)} \right)$$

$$\text{logit}(P(A)) \in (-\infty, \infty)$$

$$\text{logit}(P(G)) = \log \left(\frac{P(G)}{P(S)} \right)$$

Antecedentes: Log Odds


La función logística de cualquier número α esta dado por el logit inverso:

$$\text{logit}(\alpha) = \log\left(\frac{\alpha}{\neg\alpha}\right) = \log(\alpha) - \log(\neg\alpha) \rightarrow$$

...


...

$$\text{logit}^{-1}(\alpha) = \text{logistic}(\alpha) = \frac{1}{1 + \exp(-\alpha)} = \frac{\exp(\alpha)}{\exp(\alpha) + 1}$$



Pregunta:

- a) ¿Qué pasa con el modelo y su error?
- b) ¿Cómo son los valores devueltos por el modelo?



Regresión Logística

↳ Familia de Métodos

Modelos Lineales Generalizados
(GLM)

↳ 1972 Nelder and Wedderburn

↳ Extensión de la MLR a
problemas \neq Regresión

↳ La Regresión Logística es un caso
especial de MLR

GLM

$$g(E(y)) = \alpha + \beta x_1 + \gamma x_2$$

$g(\cdot)$ Función liga

$E(\cdot)$ Función de Valor Esperado

El valor esperado de una variable aleatoria es su

MEDIA, a continuación se muestra el cálculo

a) discreta y b) Continua:

$$a) E[h(x)] = \sum_x h(x) f(x) \leftarrow h(x) \text{ en una variable aleatoria}$$

$$b) E(x) = \int_{-\infty}^{\infty} x f(x) dx$$

Ejemplo:

1000 clientes

Necesitamos predecir la probabilidad.

clientes comprar / no-comprar

$$y \in \left\{ \begin{array}{l} 0 - \text{no-compra} \\ 1 - \text{compra} \end{array} \right\}$$

a) Empecemos por plantear una regresión lineal

con $y \rightarrow g(y)$

$$g(y) = \beta_0 + \beta_1 (\text{age}) \quad \textcircled{a}$$

En Reg. Logística se busca:

- Estimar $P(\cdot)$ del resultado de y

Para ello $g(\cdot)$ requiere 2 cosas:

- i) probabilidad de Éxito (Compra)
- ii) ✓ de Falla (No-Compra)

Estas probabilidades deben satisfacer:


$$1. P(\cdot) \geq 0$$

$$2. P(a) + P(b) \leq 1$$

Debido a estas condiciones ($Prob \geq 0$) expresaremos la regresión lineal como una función exponencial

¿Por qué?

Para cualquier valor de la pendiente m
y peso de la var. independiente el valor
será **POSITIVO** ✓



Para facilitar la notación $p = g(\cdot)$

$$p = e^{(\beta_0 + \beta_1(\text{age}))} \quad \textcircled{b}$$

Para garantizar que $P \leq 1$

$$p = \frac{e^{(\beta_0 + \beta_1(\text{age}))}}{e^{(\beta_0 + \beta_1(\text{age}))} + 1} \quad \textcircled{c}$$

Recordemos que la función liga requiere la probabilidad:

- a) De **ÉXITO**
- b) De **FALLA**

De acuerdo a la ecuación ©,
la probabilidad de ÉXITO se expresa:

$$p = \frac{e^y}{e^y + 1}$$

↑
Función LOGIT

en este caso p es
la probabilidad de
ÉXITO

Entonces para $p(\text{FALLA}) = q$

$$q = 1 - p = 1 - \left(\frac{e^y}{e^y + 1} \right)$$

Si dividimos p/q

$$\frac{p}{q} = \frac{\frac{e^y}{e^y + 1}}{1 - \frac{e^y}{e^y + 1}} = \frac{\frac{e^y}{e^y + 1}}{\frac{e^y + 1 - e^y}{e^y + 1}} = \left(\frac{\frac{e^y}{e^y + 1}}{\frac{1}{e^y + 1}} \right)$$

$$= \frac{e^{2y} + e^y}{e^y + 1} = \frac{e^y (e^y + 1)}{e^y + 1} = e^y$$

Entonces si p/q

$$p/q = \boxed{\frac{p}{1-p} = e^y}$$

$$\rightarrow \log\left(\frac{p}{1-p}\right) = y$$

Función Log!!!

Pregunta: $\log\left(\frac{p}{1-p}\right)$ es lineal? NO


Una asociación NO-LINEAL con un modelo
Lineal

El modelo
entonces queda:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1$$

log - odds!!

• Una gráfica típica de la regresión logística



• Comentarios del Modelo:

1. Cuando $\log\left(\frac{p}{1-p}\right) > 0$

↳ la probabilidad de **ÉXITO** es $> 50\%$.